

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ИНДИВИДУАЛЬНОЕ ДОМАШНЕЕ ЗАДАНИЕ
по дисциплине «Введение в нереляционные базы данных»
Тема: База данных препринтов из arXiv

Студент гр. 7382	_____	Гиззатов А.
Студент гр. 7383	_____	Бергалиев М.
Студентка гр. 7383	_____	Тян Е.
Преподаватель	_____	Заславский М.М.

Санкт-Петербург
2020

ЗАДАНИЕ НА ИНДИВИДУАЛЬНОЕ ДОМАШНЕЕ ЗАДАНИЕ

Студент Гиззатов А.

Группа 7382

Студент Бергалиев М., Тяп Е.

Группа 7383

Тема работы: БД препринтов из arXiv

Исходные данные:

Предлагаемая БД – Neo4j

Набор данных – <https://www.kaggle.com/Cornell-University/arxiv>

Нужно импортировать весь датасет. Интересно: быстрый импорт, статистика, поиск, анализ связей между документами (ссылки друг на друга)

Содержание пояснительной записки:

«Содержание»

«Введение»

«Качественные требования к решению»

«Сценарий использования»

«Модель данных»

«Разработка приложения»

«Вывод»

«Приложение»

Предполагаемый объем пояснительной записки:

Не менее 10 страниц.

Дата выдачи задания: 05.10.2000

Дата сдачи реферата: 20.12.2020

Дата защиты реферата: 20.12.2020

Студент гр. 7382

Гиззатов А.

Студент гр. 7383

Бергалиев М.

Студентка гр. 7383

Тян Е.

Преподаватель

Заславский М.М.

АННОТАЦИЯ

Была поставлена задача написания веб-приложения, предоставляющего возможность взаимодействия с БД препринтов arXiv.

SUMMARY

The task was to write a web application that provides the ability to interact with the arXiv preprint database.

СОДЕРЖАНИЕ

1.	Введение	6
a.	Постановка задачи	6
b.	Предлагаемое решение	6
2.	Качественные требования к решению	7
a.	Текущие	7
3.	Сценарии использования	8
a.	Макет ui	8
b.	Сценарии использования	8
4.	Модель данных	14
a.	Нереляционная модель данных	14
b.	Аналог модели данных для sql субд	15
c.	Сравнение моделей	17
5.	Разработанное приложение	18
a.	Краткое описание	18
b.	Схема экранов приложения	18
c.	Использованные технологии	19
d.	Ссылки на приложение	19
6.	Выводы	20
a.	Достигнутые результаты	20
b.	Недостатки и пути для улучшения полученного решения	20
c.	Будущее развитие решения	20
7.	Приложения	21
a.	Документация по сборке и развёртыванию приложения	21
8.	Список использованных источников	22

1. ВВЕДЕНИЕ

а. Постановка задачи.

Реализовать веб-приложение, представляющее возможность взаимодействия с БД препринтов из arXiv.

б. Предлагаемое решение.

Приложение создано на языке Python 3 с использованием СУБД Neo4j. В приложении доступен поиск по автору/названию статьи/категориям. Присутствуют статистики по авторам с наибольшим количеством статей и по категориям. Реализован анализ связей между соавторами.

2. КАЧЕСТВЕННЫЕ ТРЕБОВАНИЯ К РЕШЕНИЮ.

а. Текущие.

- Импортировать весь датасет, представленный на <https://www.kaggle.com/Cornell-University/arxiv>.
- Обратить внимание на реализацию быстрого импорта, статистик, поиска, анализа связей между документами (ссылки друг на друга).
- Использовать СУБД Neo4j.

3. СЦЕНАРИИ ИСПОЛЬЗОВАНИЯ.

а. Макет UI.

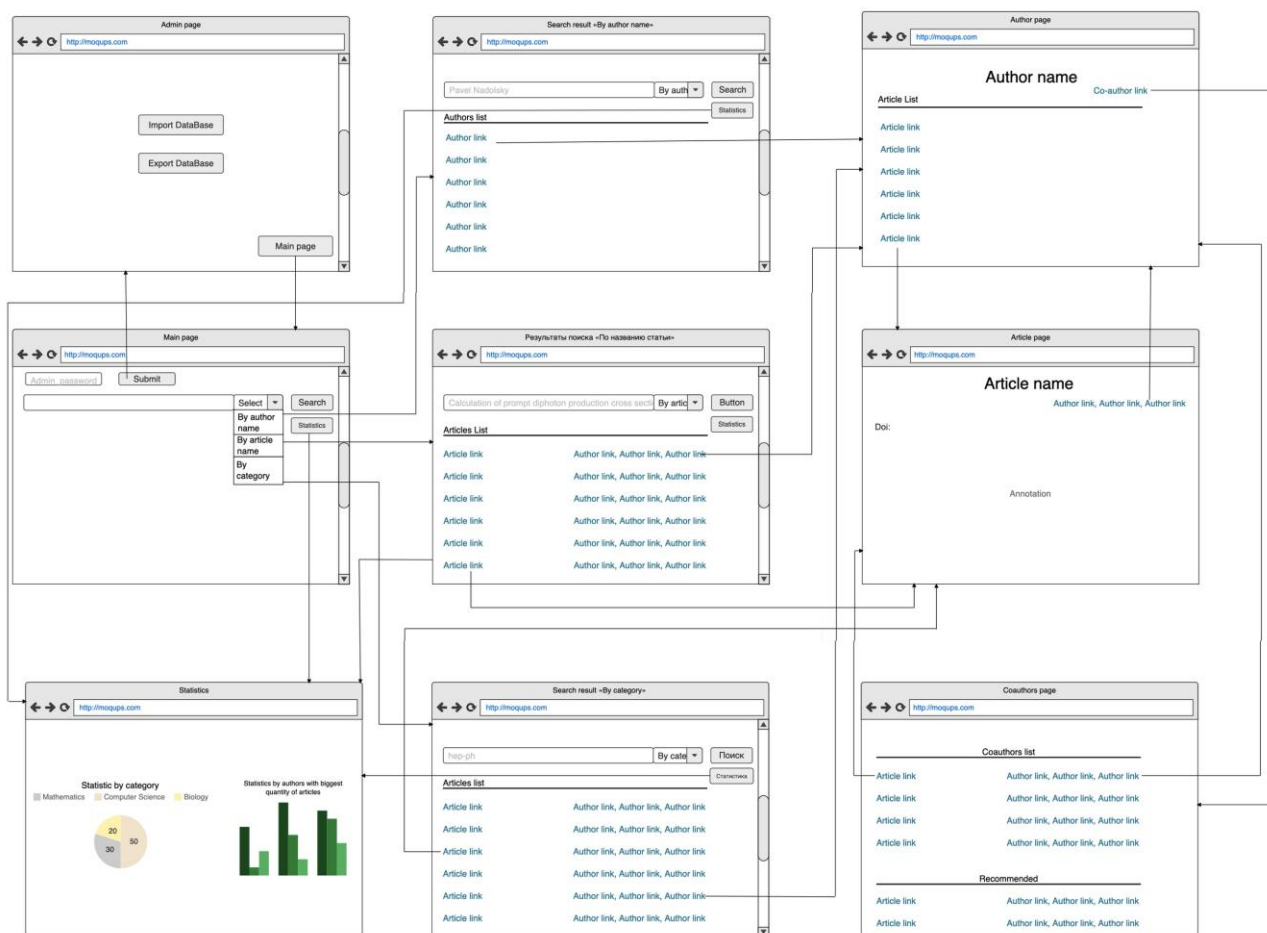


Рисунок 1 — Макет UI

б. Сценарии использования.

I. Импорта данных:

А. Действующее лицо – Admin. Admin имеет возможность загружать данные в программу массово из файла:

- 1) Admin заходит на сайт приложения.
- 2) Admin попадает на веб-страницу «Admin page», введя пароль и перейдя по кнопке «submit».
- 3) Admin импортирует данные в БД с использованием кнопки «import».

II. Представления данных:

А. Действующее лицо – пользователь. Просмотр статьи, найденной по автору/названию статьи/категориям:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь может выбрать, по какому критерию искать статью (автор, название статьи или категории)
- 3) Пользователь попадает на страницу с поиском статьи по автору/названию статьи/ критериям.
- 4) Пользователь вводит в строку поиска нужную ему статью по критерию, который он выбрал.

В. Действующее лицо – пользователь. Просмотр всех статей одного автора:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по автору».
- 3) Пользователь вводит в строку поиска нужного ему автора.
- 4) Пользователь переходит на страницу, посвященную автору.

С. Действующее лицо – пользователь. Просмотр всех статей одного автора. Альтернативный сценарий:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по названию статьи».
- 3) Пользователь вводит в строку поиска нужного ему автора среди выданных статей.
- 4) Пользователь переходит на страницу, посвященную автору.

Д. Действующее лицо – пользователь. Просмотр всех статей одного автора. Альтернативный сценарий:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по категориям».
- 3) Пользователь вводит в строку поиска нужного ему автора среди найденных статей и авторов.
- 4) Пользователь переходит на страницу, посвященную автору.

Е. Действующее лицо – пользователь. Поиск соавторов выбранного автора:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по автору/названию статьи/категориям».
- 3) Пользователь вводит в строку поиска нужные параметры (автора/название статьи/категории).
- 4) Пользователь переходит на страницу, посвященную выбранному автору.
- 5) Пользователь нажимает на кнопку «Поиск соавторов» и переходит на страницу со всеми соавторами выбранного автора.

Г. Действующее лицо – пользователь. Поиск соавторов выбранного автора. Альтернативный сценарий:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по названию статьи/категориям».
- 3) Пользователь вводит в строку поиска нужные параметры (название статьи/категории).

- 4) Пользователь переходит на страницу, посвященную нужной ему статье/категориям.
- 5) Пользователь переходит на страницу автора, выбранного в результате поиска по названию статьи/категориям.
- 6) Пользователь нажимает на кнопку «Поиск соавторов» и переходит на страницу со всеми соавторами выбранного автора.

Г. Действующее лицо – пользователь. Получение информации о статье:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по автору/названию статьи/категориям».
- 3) Пользователь вводит в строку поиска нужные параметры (автора/название статьи/категории).
- 4) Пользователь выбирает необходимую статью из списка найденных.
- 5) Пользователь переходит на страницу с содержанием выбранной статьи.

Н. Действующее лицо – пользователь. Получение информации о статье. Альтернативный сценарий:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по названию статьи/категориям».
- 3) Пользователь вводит в строку поиска нужные параметры (название статьи/категории).

- 4) Пользователь переходит на страницу, посвященную списку статей, содержащих введенную часть названия/ списку статей введенной категории
- 5) Пользователь переходит на страницу с содержанием выбранной статьи.

I. Действующее лицо – пользователь. Получение информации о статье. Альтернативный сценарий:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит на старницу «Поиск по автору».
- 3) Пользователь вводит в строку поиска нужного автора.
- 4) Пользователь переходит на страницу нужного ему автора.
- 5) Пользователь переходит по кнопке на страницу с соавторами выбранного автора.
- 6) Пользователь переходит на страницу, посвященную выбранной статье из списка всей статей соавторов.

III. Анализа данных:

A. Действующее лицо – пользователь. Просмотр статистики по категориям/по авторам, с самым большим числом статей:

- 1) Пользователь заходит на сайт веб-приложения.
- 2) Пользователь переходит с главной страницы на страницу со всеми диаграммами статистик.

B. Действующее лицо – пользователь. Просмотр статистики по категориям/по авторам, с самым большим числом статей. Альтернативный сценарий:

- 3) Пользователь заходит на сайт веб-приложения.
- 4) Пользователь переходит на страницу «Поиск по автору/названию статьи/категориям».
- 5) Пользователь переходит с на страницу со всеми диаграммами статистик.

IV. Экспорта данных:

А. Действующее лицо – Admin. Admin имеет возможность экспортировать данные массово в файл:

- 1) Admin заходит на сайт приложения.
- 2) Admin попадает на веб-страницу «Admin page», введя пароль и перейдя по кнопке «submit».
- 3) Admin импортирует данные из БД с использованием кнопки «export».

Возможность пользователя просматривать данные реализовано с помощью веб-интерфейса.

Массовое добавление данных в БД реализовано по 50 элементов из-за большого объема данных.

Для данного решения преобладают операции чтения, т.к. операции записи используются только в случае записи данных из БД на сервер. Операции чтения используются каждый раз при отображении информации.

4. МОДЕЛЬ ДАННЫХ.

а. Нереляционная модель данных.

I. Графическое представление, изображено на рис. 2.

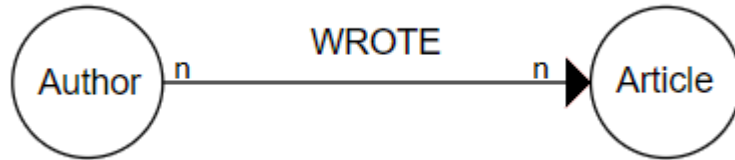


Рисунок 2 — Графическое представление

II. Описание назначений коллекций, типов данных и сущностей:

Сущность Author. Атрибуты:

- name – Ф.И.О. автора, строковый тип String. Средняя длина n – символов.

Сущность Article. Атрибуты:

- title – заголовок (название) статьи, строковый тип String. Средняя длина – t символов.
 - doi – doi цифровой идентификатор статьи. Средняя длина d – символов.
 - abstract – аннотация статьи, строковый тип String. Средняя длина – a символов.
 - category – категория статьи, строковый тип String. Средняя длина – c символов.
- Связь WROTE авторства человека над статьей. Атрибутов не имеет. Среднее число авторов у статьи – 3.

III. Оценка удельного объема информации, хранимой в модели.

Пусть уникальный идентификатор вершин и связей имеет размер 12 байт, размер символа – 2 байта. Связь хранит идентификаторы вершин, которые связывает, и название связи. Названия атрибутов вершин также влияют на размер. Будем считать, что всего N статей и N авторов. Тогда размер БД

$$(12 + 24 + 2 * n) * N + (12 + 25 + 2 * t + 23 + 2 * d + 28 + 2 * a + 28 + 2 * c) * N + (12 + 12 + 25) * 3 * N$$

Приняв, что $n = 13$, $t = 80$, $d = 27$, $a = 1000$, $c = 7$. Получим оценку размера БД – $46 * N + 2272 * N + 102 * N = 2420N$.

«Чистые» данные не содержат идентификаторов, хранение названия атрибутов и название связи. Тогда объем «чистых» данных:
 $26 * N + 2228 * N + 72 * N = 2326N$.

Вычислим соотношение фактического и «чистого» объема данных:

$$2420N / 2326N = 1.0404$$

Как видно, модель не сильно увеличивает объем данных, поскольку основной объем занимает хранение аннотаций к статьям, которые никак не дублируются.

IV. Запросы к модели, с помощью которых реализуются сценарии использования

- Поиск автора по регулярному выражению reg_name:

MATCH (a:Author) WHERE a.name =~ reg_name RETURN a

- Поиск статьи по регулярному выражению reg_title:

MATCH (a:Article) WHERE a.title =~ reg_title RETURN a

- Поиск статьи по категории category:

MATCH (a:Article) WHERE a.category =~ category RETURN a

- Поиск соавторов автора, их соавторов и т.д.:

MATCH (a:Author)-[:WROTE*1..]-(b:Author) WHERE a.name =~ author_name RETURN b

b. Аналог модели данных для SQL СУБД

I. Графическое представление, изображено на рис. 3.

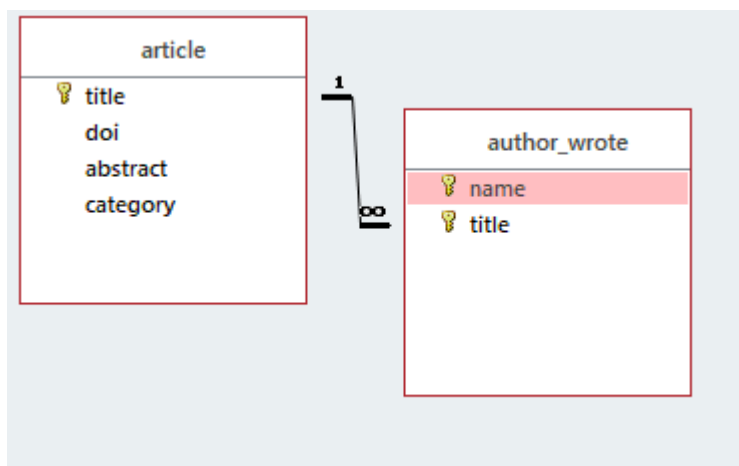


Рисунок 3 — Графическое представление

II. Описание назначений коллекций, типов данных и сущностей:

Таблица `autor_wrote`. Поля:

- `name` – Ф.И.О. автора, строковый тип `VARCHAR`. Максимальное количество символов – 50. Средняя длина – n символов.
- `title` – заголовок (название) статьи, строковый тип `TEXT`. Средняя длина – t символов.

Таблица `article`. Поля:

- `title` – заголовок (название) статьи, строковый тип `TEXT`. Средняя длина – t символов.
- `doi` – `doi` цифровой идентификатор статьи. Средняя длина d – символов.
- `abstract` – аннотация статьи, строковый тип `TEXT`. Средняя длина – a символов.
- `category` – категория статьи, строковый тип `VARCHAR`. Максимальное количество символов – 50. Средняя длина – c символов.

III. Оценка удельного объема информации, хранимой в модели.

Пусть размер символа – 2 байта. Будем считать, что всего статей и авторов. Тогда размер БД: $(2 * n + 2 * t) * N + (2 * t + 2 * a + 2 * d + 2) * N$.

Приняв, что на самом деле $n = 13$, $t = 80$, $d = 27$, $a = 1000$, $c = 7$, получим оценку размера БД – $186 * N + 2228 * N = 2414N$.

В «чистых» данных объем – $26 * N + 2228 * N = 2254N$.

Вычислим отношение фактического и «чистого» объемов данных – $2414N / 2254N = 1.07$.

Как видно, модель не сильно увеличивает объем данных, поскольку основной объем занимает хранение аннотаций к статьям, которые никак не дублируются.

IV. Запросы к модели, с помощью которых реализуются сценарии использования.

- Поиск автора по регулярному выражению `reg_name`:

```
SELECT * FROM autor_wrote
```


WHERE name LIKE reg_name

- Поиск статьи по регулярному выражению reg_title:

SELECT * FROM article

WHERE title LIKE reg_title

- Поиск статьи по категории category:

SELECT * FROM article

WHERE category LIKE category_name

- Поиск соавторов автора, их соавторов и т.д. Для поиска соавторов соавторов нужного автора необходимо выполнить 2 таких запроса. Т.е. для поиска соавторов n-вложенности нужно сделать n-запросов:

SELECT author_wrote.name FROM (SELECT * FROM author_wrote WHERE name = choosen_name) as A

ON A.title = author_wrote.title

с. Сравнение моделей.

Можно заметить, что модели хранения SQL и NOSQL схожи. Только в модели SQL необходимо дублирование заголовка статьи. Для выполнения запроса «поиск соавторов соавторов и т.д.» в случае SQL требуется выполнять n запросов только для одного соавтора. Тогда, если будет расти число соавторов, то количество запросов тоже будет неограниченно расти.

5. РАЗРАБОТАННОЕ ПРИЛОЖЕНИЕ.

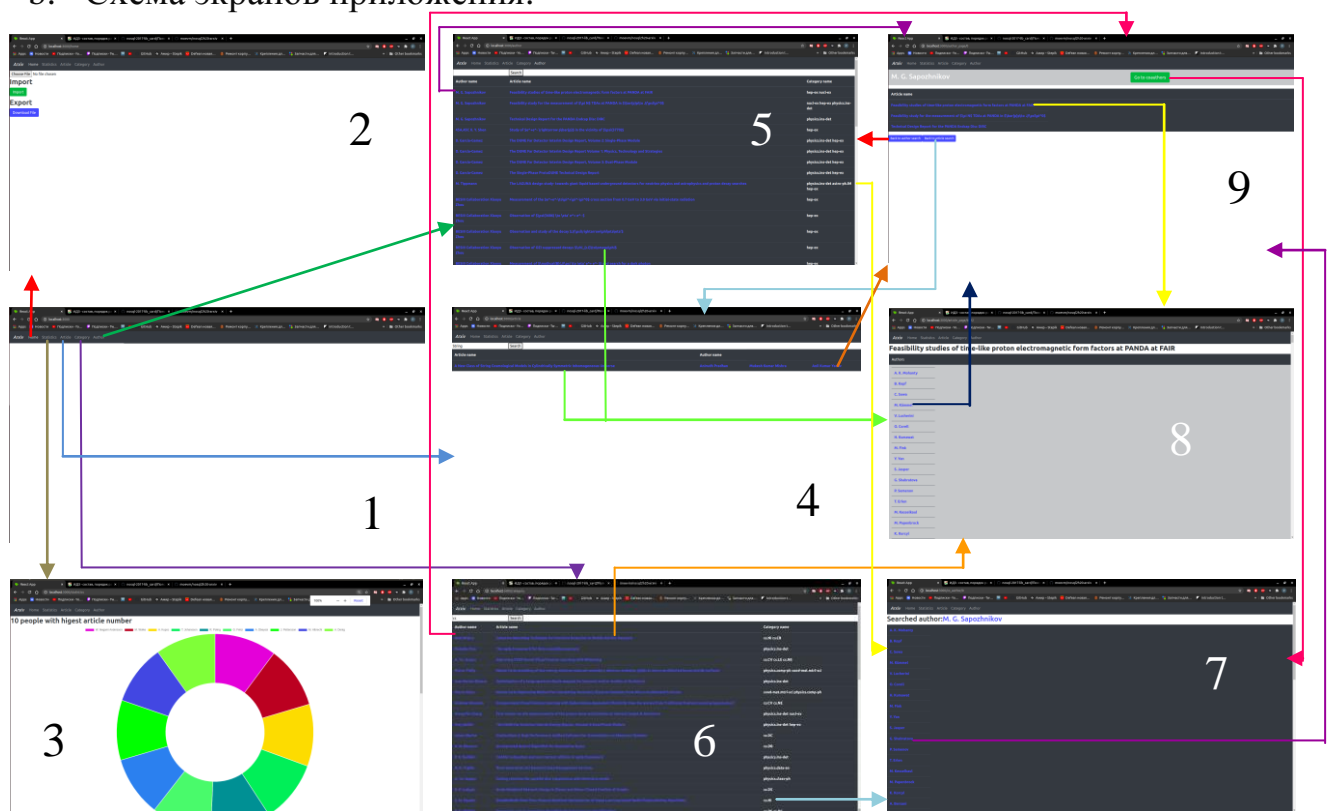
а. Краткое описание.

Реализовано веб-приложение, предоставляющее возможность взаимодействия с БД препринтов arXiv. В приложении доступен поиск по автору/названию статьи/категориям. Присутствуют статистики по авторам с наибольшим количеством статей и по категориям. Реализован поиск соавторов, т.е. анализ связей между авторами.

Back-end реализован на Python 3. Front-end – реализован с помощью React-js. Представление данных в веб-приложении происходит в следующем формате:

- 1) Данные из CSV-файла записываются в БД Neo4j.
- 2) Данные отображаются в веб-приложении посредством запросов к БД Neo4j.

б. Схема экранов приложения.



1 – Главная страница

2 – Страница импорта/экспорта данных

- 3 – Страница со статистиками
- 4 – Страница «Поиск по названию статьи»
- 5 – Страница «Поиск по автору»
- 6 – Страница «Поиск по категории»
- 7 – Страница соавторов
- 8 – Страница статьи
- 9 – Страница автора

с. Используемые технологии.

БД: Neo4j

Back-end: Python 3

Front-end: React-js

d. Ссылки на Приложение.

Ссылка на github: <https://github.com/moevm/nosql2h20-arxiv>

6. ВЫВОДЫ.

а. Достигнутые результаты.

Реализовано веб-приложение, предоставляющее возможность взаимодействия с БД препринтов arXiv. В приложении доступен поиск по автору/названию статьи/категориям. Присутствуют статистики по авторам с наибольшим количеством статей и по категориям. Реализован поиск соавторов, т.е. анализ связей между авторами.

б. Недостатки и пути для улучшения полученного решения.

Реализован импорт/экспорт данных в формате CSV. Для данного решения файл с данными скачивается полностью. Для отображения данных на веб-страницах грузится по 50 экземпляров.

с. Будущее развитие решения.

Дальнейшее развитие приложения предполагает увеличение числа форматов для импорта-экспорта данных, загрузку данных пакетами, не целым файлом. Также можно предусмотреть загрузку более 50 экземпляров данных.

7. ПРИЛОЖЕНИЯ.

а. Документация по сборке и развёртыванию приложения.

Необходимо скачать проект из репозитория.

Перед запуском проекта необходимо убедиться, что порты 5000, 3000, 7687, 7474 не заняты. Инструкции для Docker:

```
docker-compose build --no-cache
```

```
docker-compose up
```

или

```
docker-compose up --build
```

После сборки и запуска проекта БД будет пустая. Проект запустится на 300 порту.

Импорт данных в БД.

Для демонстрации импорта данных в БД есть файл `import.zip`, который нужно добавить на странице Admin, нажав кнопку «import». На страницу Admin можно перейти с главной страницы по кнопке «Home». При этом нужно учесть, что:

- Импорт принимает только архив с 3 файлами: `articles.csv`, `authors.csv`, `wrote.csv`
- Максимальное время импорта данных в БД – 5 минут, в противном случае – появляется ошибка.

Экспорт данных из БД.

На странице Admin, на которую можно перейти по кнопке «Home» с главной страницы, можно выполнить экспорт данных с помощью кнопки «export». При этом будет скачан архив `export.zip` с 50 вершинами для авторов и статей, а также 50 связей.

8. СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.

- a. Документация Neo4j: <https://neo4j.com/docs/>
- b. Документация React-js: <https://ru.reactjs.org/docs/getting-started.html>
- c. Документация Docker: <https://dker.ru/docs/>